



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

bc

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-7 «Программное обеспечение ЭВМ и информационные технологии»

**РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ
НА ТЕМУ:**

***«Применение машинного обучения в поисковых
системах»***

Студент ИУ7-51Б

_____ Волков Г.В.

Руководитель

_____ Шаповалова М.С.

РЕФЕРАТ

Расчетно-пояснительная записка 27 с., 3 рис., 9 источников, 1 прил.

МАШИННОЕ ОБУЧЕНИЕ, ОБУЧЕНИЕ РАНЖИРОВАНИЮ, НЕЙРОННЫЕ СЕТИ, LINEAR REGRESSION, RANKING SVM, LAMBDA RANK, LISTNET

Объектом исследования являются методы машинного обучения, применяемые в поисковых системах.

Цель работы — рассмотрение алгоритмов машинного обучения, в частности, их применение в поисковых системах.

В процессе работы были изучены существующие методы обучения ранжированию и проведён их сравнительный анализ.

СОДЕРЖАНИЕ

РЕФЕРАТ	3
ВВЕДЕНИЕ	5
1 Анализ предметной области	7
1.1 Основные понятия	7
1.2 Применение машинного обучения в поисковых системах	8
2 Исследование существующих алгоритмов обучения ранжированию	10
2.1 Классификация алгоритмов	10
2.2 Алгоритмы обучения ранжированию	11
2.2.1 Linear Regression	12
2.2.2 OC SVM	13
2.2.3 Ranking SVM	14
2.2.4 LambdaRank	14
2.2.5 ListNet	16
3 Сравнение алгоритмов обучения ранжированию	19
3.1 Критерии сравнения	19
3.2 Сравнение алгоритмов	21
3.3 Вывод	22
ЗАКЛЮЧЕНИЕ	23
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	24
ПРИЛОЖЕНИЕ А Презентация научно-исследовательской работы	25

ВВЕДЕНИЕ

Машинное обучение — термин, обозначающий набор методов и инструментов, которые помогают компьютерам самостоятельно обучаться и адаптироваться. Алгоритмы машинного обучения помогают ИИ учиться, не будучи явно запрограммированным на выполнение желаемого действия, обрабатывая специально подобранные входные данные. Технологии связанные с машинным обучением стремительно развиваются и используются людьми во многих сферах жизни, например:

- распознавание изображений и речи;
- прогнозирование автомобильного трафика;
- рекомендательные системы;
- автопилот;
- медицина;
- виртуальные помощники;
- поисковые системы;

Целью же данной научно–исследовательской работы является рассмотрение алгоритмов машинного обучения, в частности, их применение в поисковых системах.

Актуальность этой темы объясняется широким распространением поисковых систем. Большинство людей ежедневно совершают множество запросов в поисках нужной информации. Для ускорения и улучшения качества поисковой выдачи применяются методы машинного обучения, а именно обучение ранжированию. Современные поисковики используют машинное обучение, например, Матрикснет в Яндексе.

Для достижения поставленной в работе цели предстоит решить следующие задачи:

- изучить основные понятия алгоритмов обучения ранжированию;
- ознакомиться с существующими алгоритмами и классифицировать их;

— произвести сравнительный анализ рассмотренных алгоритмов.

1 Анализ предметной области

1.1 Основные понятия

Машинное обучение — раздел информатики, посвященный созданию алгоритмов, опирающихся на набор данных о каком-либо явлении. Данные получают из естественной среды, создают вручную или генерируют другим алгоритмом. Методы машинного обучения формируют статистическую модель на основе специально подобранных обучающих данных, которую потом используются для решения практических задач [1].

Выделяется три основных способа обучения: с учителем, без учителя и с подкреплением. Способы и их применение проиллюстрированы на рисунке 1.1.

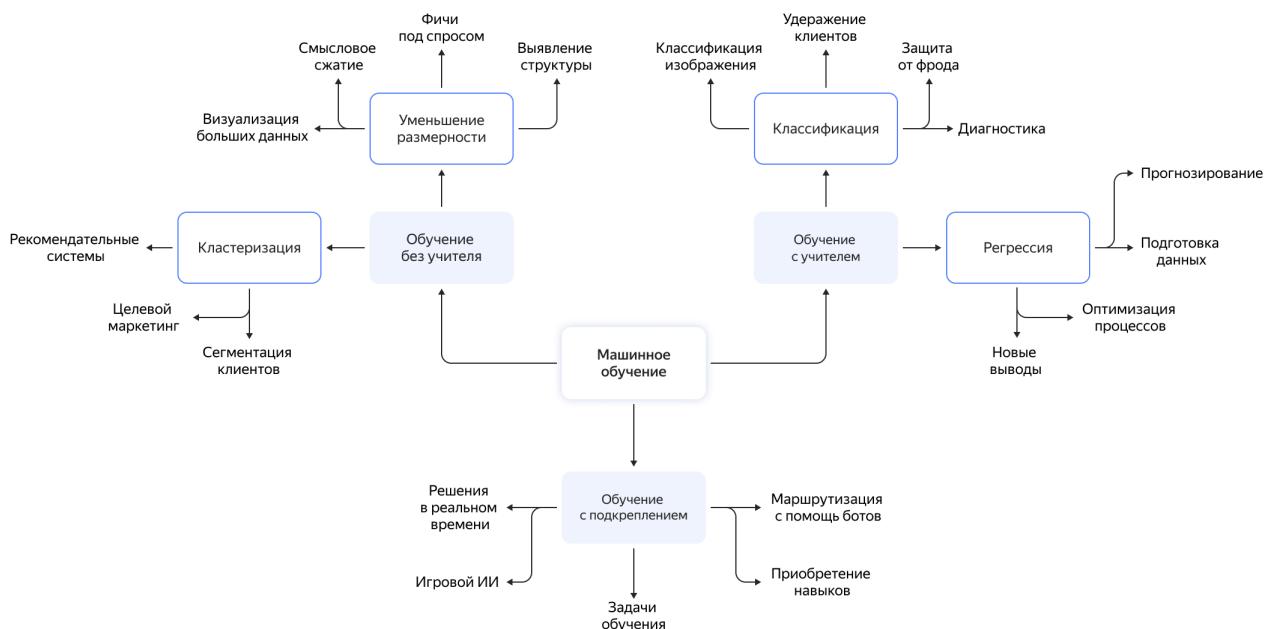


Рисунок 1.1 – Способы обучения

В обучении с учителем набор данных организован как коллекция размеченных образцов вида «известный вход — известный выход», называемый обучающей выборкой. Существует некоторая зависимость между входом и выходом, но она неизвестна. При обучении создаётся модель, отражающая эту зависимость, способная для любого входа выдать достаточно точный выход. Каждый вход является вектором признаков, описывающих некоторые характеристики образца. Выход может быть элементом конечного множества,

вещественным числом или более сложной структурой. В основном используется для задач регрессии и классификации.

Обучение без учителя — класс задач машинного обучения, в которых известны только описания множества объектов и требуется обнаружить внутренние взаимосвязи. На вход подаётся вектор признаков, а целью алгоритма обучения без учителя является — создать модель, которая принимает входные параметры и преобразует их в значение, которое можно использовать для решения практической задачи. Используются для задач кластеризации, уменьшения размерности и выявления аномалий.

Обучение с подкреплением — это раздел машинного обучения, в котором предполагается, что машина «живет» в определенном окружении и способна воспринимать его как вектор характеристик. Идея заключается в том, что компьютер взаимодействует со средой, параллельно обучаясь, и получает вознаграждение за выполнение действий т. е. обучается методом проб и ошибок. Цель алгоритма обучения с подкреплением — выучить линию поведения, которая приводит к максимальному ожидаемому вознаграждению.

1.2 Применение машинного обучения в поисковых системах

Работа поисковой системы заключается в том, чтобы по запросу пользователя найти документы, наилучшим образом удовлетворяющие информационную потребность пользователя. При этом основными критериями качества результатов информационного поиска являются полнота, точность и оперативность поиска. Сайты в поисковой выдаче сортируются в соответствии с факторами, используемыми поисковым движком т. е. проходят процедуру ранжирования.

Существует множество методов подбора формулы для ранжирования, но один из самых популярных — на основе машинного обучения, а именно обучение ранжированию с учителем. Целью этих методов является подбор ранжирующей модели по обучающей выборке, которая способна наилучшим образом приблизить и обобщить способ ранжирования на новые данные. Для получения набора примеров используют асессоров, которые оценивают сте-

пень релевантности документа запросу. Данные для обучения характеризуются большим объёмом (100 – 500 тысяч примеров) и большой размерностью (100 – 1000 признаков) [2].

2 Исследование существующих алгоритмов обучения ранжированию

2.1 Классификация алгоритмов

Существующие алгоритмы обучения ранжированию делятся на три группы по подходу к обучению [3]: поточечный, попарный и списочный.

Поточечный подход — частный случай задачи регрессии или классификации, если множество оценок конечно, в ходе ее решения возможно использовать метод градиентного спуска, опорных векторов и т. д. На практике этот подход дает не очень качественный результат, так как каждый документ ранжируется независимо от других. В качестве примеров для обучения используют пары «признаки — значение релевантности». Данная задача может быть аппроксимирована задачей регрессии — учитывая единственную пару «запрос — документ», спрогнозируйте ее оценку. Точечный подход направлен на изучение функции, предсказывающей реальное значение или порядковый номер документа, используя функцию потерь.

При попарном подходе обучение ранжированию сводится к построению бинарного классификатора, которому на вход поступают два документа, соответствующих одному и тому же запросу, и требуется определить, какой из релевантнее. Классификатор должен принимать два документа в качестве входных данных, и цель состоит в том, чтобы минимизировать функцию потерь. Недостатком также является то, что данный подход не учитывает все документы запроса. Помимо этого целью обучения таких алгоритмов является минимизация ошибок в классификации пар документов, а не минимизация ошибок в ранжировании документов, процесс обучения требует больших вычислительных затрат, количество сгенерированных пар документов в значительной степени варьируется от запроса к запросу, что приводит к обучению модели, ориентированной на запросы с большим количеством пар.

Списочный подход заключается в построении модели, на вход которой поступают сразу все документы, соответствующие запросу, а на выходе получается их перестановка. Подгонка параметров модели осуществляется для прямой максимизации одной метрик ранжирования. Но это часто затрудни-

тельно, так как метрики ранжирования обычно не непрерывны и недифференцируемы относительно параметров ранжирующей модели, поэтому прибегают к максимизации неких их приближений или нижних оценок. С точки зрения поставленной задачи ранжирования, списочные методы являются методами, которые решают исходную постановку задачи. Является одним из самых лучших методов на данный момент, но они сложны в разработке и подборе обучающих наборов данных

2.2 Алгоритмы обучения ранжированию

В данном разделе будут рассмотрены несколько популярных алгоритмов из каждой категории: Linear Regression (поточечный), OC SVM (поточечный), Ranking SVM (парный), LambdaRank(парный), ListNet(списочный).

Перед описанием алгоритмов стоит введём следующие обозначения:

- q_i — i -ый поисковый запрос;
- D_i — список всех документов, которые ассоциированы с q_i запросом;
- $d_{i,j}$ — j -ый документ из списка D_i ;
- π_i — отсортированный список D_i ;
- $y_{i,j}$ — метка, показывающая на сколько документ $d_{i,j}$ релевантен к запросу q_i ;
- y_i — вектор меток $y_{i,j}$.

На этапе ранжирования методы имеют схожий алгоритм. Для каждого документа $d_{i,j}$ вычисляется рейтинг релевантности, который зависит от вектора признаков документа $x_{i,j}$ и параметров метода ранжирования ω . Затем рейтинги сортируются по убыванию и получается отранжированный список документов. Признаки документов зависят не только от описания документов, но и от функции от поискового запроса и документа.

2.2.1 Linear Regression

Рассматриваем метод обучения на основе регрессии для решения задачи оптимизации метрик DCG [4]. Пусть F — функциональное пространство, содержащее функции $X \times S \rightarrow F$, где X — множество векторов представления документов, S — множества всех конечных подмножеств X . Произвольно созданы множества S_1, \dots, S_n , где $S_i = \{x_{i,1}, \dots, x_{i,m}\}$, с соответствующими оценками $\{y_{i,j}\}_j = \{y_{i,1}, \dots, y_{i,m}\}$. Тогда для решения проблемы ранжирования можно использовать простой подход, основанный на регрессии:

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \left[\sum_{j=1}^m (f(x_{i,j}, S_i) - y_{i,j})^2 \right].$$

Однако этот метод прямой регрессии не подходит для крупномасштабных задач ранжирования, таких как веб-поиск, для которых требуется ранжировать множество элементов, но важны только страницы с самым высоким рейтингом. Это связано с тем, что метод уделяет равное внимание релевантным и нерелевантным страницам. На самом деле, следует уделять больше внимания страницам с самым высоким рейтингом. Оценки страниц с низкой релевантностью не нуждаются в большой точности, до тех пор, пока мы не переоцениваем их, чтобы эти страницы отображались на верхних позициях в поиске. С учётом этого рассуждений стоит использовать следующий метод обучения:

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n L(f, S_i, \{y_{i,j}\}_j),$$

где для $S = \{x_1, \dots, x_m\}$, с соответствующим $\{y_j\}_j$, имеем:

$$\begin{aligned} L(f, S, \{y_j\}_j) \\ = \sum_{j=1}^m w(x_j, S)(f(x_j, S) - y_j)^2 + u \sup_j w'(x_j, S)(f(x_j, S) - \delta(x_j, S))_+^2, \end{aligned}$$

где u — неотрицательный параметр. Весовая функция $w(x_j, S)$ выбрана таким образом, чтобы она фокусировалась только на наиболее важных документах. Во второй части уравнения мы выбирается $w'(x_j, S)$ так, чтобы она фокусировалась на страницах, не охваченных $w(x_j, S)$. $\delta(x_j, S)$ выбирается

в качестве нижнего порога. Важной особенностью является то, что, хотя t часто очень велико, количество точек, при которых $w(x_j, S)$ отлично от нуля, зачастую достаточно мало. Более того, $(f(x_j, S) - \delta(x_j, S))_+$ не равно нулю только тогда, когда $f(x_j, S) \geq \delta(x_j, S)$. Следовательно, полностью игнорируются низкоранговые страницы, что делает алгоритм вычислительно эффективным даже при большом t .

2.2.2 ОС SVM

ОС SVM является одним из базовых алгоритмов ранжирования. Алгоритм заключается в построении гиперплоскостей, которые выступают в роли разделителей. По взаиморасположение документа $d_{i,j}$ и гиперплоскостей делается предсказание о степени релевантности документа. Перегруппировав все векторные представления документов $x_{i,j}$ по степени релевантности, получим $\hat{x}_{r,k}$ — вектор признаков k -ого по счету документа, у которого степень релевантности равна $r = y_{r,k}$, и пусть таких документов m_r . Тогда задачу поиска таких ω и b_r можно поставить следующим образом:

$$\begin{cases} \frac{1}{2}\|\omega\|^2 + C \sum_{r=1}^{l-1} \sum_{k=1}^{m_r} (\xi_{r,k} + \hat{\xi}_{r,k}) \rightarrow \min_{\omega, b, \xi, \hat{\xi}} \\ (\omega, \hat{x}_{r,k}) - b_r \leq -1 + \xi_{r,k} \\ (\omega, \hat{x}_{r,k}) - b_r \leq 1 + \hat{\xi}_{r,k} \\ \xi_{r,k}, \hat{\xi}_{r,k} \geq 0 \end{cases},$$

где $\xi_{r,k}$ характеризует величину ошибки для $x_{r,k}$, C — параметр, позволяющий регулировать отношение между максимизацией ширины разделяющей полосы и минимизацией суммарной ошибки. Получается стандартная задача квадратичного программирования. Алгоритм пытается проводить гиперплоскости, с максимальным отступом от элементов.

2.2.3 Ranking SVM

Ключевая идея алгоритма, предложенного Р. Хербрихом [5], заключается в использовании метода SVM для попарного сравнения документов на то, какой из элементов более релевантный.

Пусть имеется функция $f(x)$, которая определяет релевантность документа относительно запроса. Тогда утверждение о том, что документ x_i релевантнее чем документ x_j ($x_i \succ x_j$) эквивалентно тому, что $f(x_i) > f(x_j)$. Тогда если выбрать функцию $f(x) = (\omega, x)$ то имеем, что:

$$f(x_i) > f(x_j) \iff (\omega, x_i - x_j) > 0.$$

Теперь рассматривая разность векторов как новые объекты $\hat{x}_{i,j} = x_i - x_j$, получаем стандартную постановку SVM алгоритма. Теперь задача ставится следующим образом:

$$\begin{cases} \frac{1}{2}\|\omega\|^2 + C \sum_{i=1}^N \xi_i \rightarrow \min_{\omega, \xi} \\ y_i(\omega, x_i^1 - x_i^2) \leq 1 - \xi_i \\ \xi_i \geq 0 \end{cases},$$

где N — количество пар объектов, x_i^1, x_i^2 — первый и второй объект пары соответственно. При этом $y_i = 1$, если $x_i^1 \succ x_i^2$, иначе $y_i = -1$. Допустимы парами являются документы из одного списка и с различной степенью релевантности.

2.2.4 LambdaRank

В поточечных и попарных методах ранжирования итоговый функционал при обучении обычно не дифференцируемый, так как зависит от порядка элементов. В рассматриваемом алгоритме, описанном Бургес [6], вместо исходного функционала рассматривается непрерывный аналог, который легко оптимизировать. Рассмотрим работу метода для одного поискового запроса. Алгоритм LambdaRank не определяет непрерывный приближенный функци-

онал L , вместо этого он определяет градиент функционала на всем списке документов:

$$\frac{\partial L}{\partial s_i} = -\lambda(s_1, y_1, \dots, s_n, y_n),$$

где s_i — рейтинг документа, y_i — степень релевантности, а n — количество документов. Градиент выбранного документу зависит от рейтингов и степени релевантности других и пересчитывается после каждой генерации списка.

Один из способов добиться повышения эффективности — увеличение градиента документов на первых позициях, то есть более значимыми сделать перестановки с первыми элементами. Для двух документов d_i и d_j имеем, если $d_i \succ d_j$, то $|\frac{\partial L}{\partial s_i}| > |\frac{\partial L}{\partial s_j}|$.

Метод позволяет настраиваться на широкий класс функционалов качества, однако в стандартном варианте λ вычисляется по метрике NDCG:

$$\lambda_i = \frac{\partial L}{\partial s_i} = \frac{1}{G_{max}} \sum_j \left(\frac{1}{1 + \exp(s_j - si)} \right) (G(y_j) - G(y_i)) (D(\pi_j) - D(\pi_i)),$$

где функции G , D — функции преобразования релевантности документа в его рейтинг и порядковой номера документа в ранжированном списке. λ_i — показывает насколько надо увеличить рейтинг i -го документа. Для этого надо изменить веса ω :

$$\frac{\partial L}{\partial \omega} = \sum_{i=1}^n \frac{\partial s_i}{\partial \omega} \sum_{j \in P_i} \frac{\partial L(s_i, s_j)}{\partial s_i} + \sum_{j=1}^n \frac{\partial s_j}{\partial \omega} \sum_{i \in P_j} \frac{\partial L(s_i, s_j)}{\partial s_j},$$

где P_i , P_i — множество пар документов с индексами j и i , для которых пары (i, j) во множестве пар документов P соответственно.

Таким образом, алгоритм LambdaRank заключается в итерационном пересчете весов ω :

$$\omega = \omega - \eta \frac{\partial L}{\partial \omega},$$

где η — итерационный шаг. Если запросов несколько, то необходимо расширить множество P , которое может быть построено как и в методе Ranking SVM.

2.2.5 ListNet

Впервые алгоритм был описан З. КАО [7]. Цель обучения формализована как минимизация общих потерь в отношении обучающих данных.

$$\sum_{i=1}^m L(y^{(i)}, z^{(i)}),$$

где L — функция потерь по списку. В данном алгоритме предлагается использовать вероятностные модели для вычисления функции потерь L по списку. Пусть набор объектов, подлежащих ранжированию, идентифицируется числами $1, 2, \dots, n$. Перестановка π на объектах определяется как биекция от $\{1, 2, \dots, n\}$ к самой себе, т. е. $\pi = (\pi(1), \dots, \pi(n))$. Здесь $\pi(j)$ обозначает объект в позиции j в перестановке. Множество всех возможных перестановок n объектов обозначается как Ω_n . Пусть существует функция ранжирования, которая присваивает оценки n объектам. Обозначим список оценок как $s = (s_1, s_2, \dots, s_n)$, где s_j — оценка j -го объекта.

Предполагается, что возможна любая перестановка, но разные перестановки могут иметь разную вероятность, рассчитанную на основе функции ранжирования. Определим вероятность перестановки таким образом, чтобы она обладала желаемыми свойствами. Тогда вероятность перестановки π , заданная списком оценок s , определяется как:

$$P_s(\pi) = \prod_{j=1}^n \frac{\phi(s_{\pi(j)})}{\sum_{k=j}^n \phi(s_{\pi(k)})},$$

где $\phi(s_{\pi(j)})$ — это оценка объекта в позиции j перестановки π , ϕ — возрастающая и строго положительная функция.

Для любого списка ранжирования, основанного на данной функции, если поменять позицию объекта с высоким и низким баллом местами, получим список с меньшей вероятностью перестановки. Список объектов, отсортированных на основе функции ранжирования, имеет наибольшую вероятность перестановки, в то время как список объектов, отсортированных в обратном порядке, имеет наименьшую вероятность. То есть наиболее вероятной перестановкой является, отсортированная с помощью функции ранжирования.

Имея два списка оценок, мы можем сначала вычислить из них два распределения вероятностей перестановок, а затем вычислить расстояние между двумя распределениями как функцию потерь по списку. Однако, поскольку число перестановок равно $n!$, вычисление может оказаться крайне трудозатратным.

Чтобы справиться с данной проблемой, рассмотрим использование вероятности того, что j -ый документ будет ранжирован выше всех, учитывая оценки остальных документов,

$$P_s(j) = \frac{\phi(s_j)}{\sum_{k=1}^n \phi(s_k)}.$$

Используя перекрестную энтропию в качестве метрики, функцию потерь можно записать в так:

$$L(y^{(i)}, z^{(i)}) = - \sum_{j=1}^n P_{y^{(i)}}(j) \log(P_{z^{(i)}}(j)).$$

Обозначим функцию ранжирования, основанную на модели нейронной сети ω как f_ω . Функция f_ω присваивает вектору признаков $x_j^{(i)}$ значение рейтинга. Определим ϕ как экспоненциальную функцию, тогда

$$P_s(j) = \frac{\phi(s_j)}{\sum_{k=1}^n \phi(s_k)} = \frac{\exp(s_j)}{\sum_{k=1}^n \exp(s_k)}.$$

Имея запрос $q^{(i)}$ ранжирующая функция создаёт список рейтингов

$$z^{(i)}(f_\omega) = (f_\omega(x_1^{(i)}), f_\omega(x_2^{(i)}), \dots, f_\omega(x_{n^{(i)}}^{(i)})).$$

Тогда функция вероятности можно записать как:

$$P_{z^{(i)}(f_\omega)}(x_j^{(i)}) = \frac{\exp(f_\omega(x_j^{(i)}))}{\sum_{k=1}^{n^{(i)}} \exp(f_\omega(x_k^{(i)}))}.$$

С перекрестной энтропией в качестве метрики, функции потери примет вид

$$L(y^{(i)}, z^{(i)}(f_\omega)) = - \sum_{j=1}^{n^{(i)}} P_{y^{(i)}}(x_j^{(i)}) \log(P_{z^{(i)}(f_\omega)}(x_j^{(i)}))$$

Градиент функции потери можно найти по следующей формуле:

$$\begin{aligned}\Delta\omega = \frac{\partial L(y^{(i)}, z^{(i)}(f_\omega))}{\partial \omega} &= - \sum_{j=1}^{n^{(i)}} P_{y^{(i)}}(x_j^{(i)}) \frac{\partial f_\omega(x_j^{(i)})}{\partial \omega} \\ &+ \frac{1}{\sum_{j=1}^{n^{(i)}} \exp(f_\omega(x_j^{(i)}))} \sum_{j=1}^{n^{(i)}} \exp(f_\omega(x_j^{(i)})) \frac{\partial f_\omega(x_j^{(i)})}{\partial \omega}\end{aligned}$$

Метод ListNet заключается в итерационном пересчете $\Delta\omega$ и обновлении весов модели: $\omega = \omega - \eta \Delta\omega$.

3 Сравнение алгоритмов обучения ранжированию

3.1 Критерии сравнения

В качестве критериев сравнения используются основные метрики оценки качества ранжирования: MAP, NDCG [8].

Рассмотрим множество документов D . Для каждого запроса q результатом работы алгоритма ранжирования будет отображение $f : d \rightarrow R$, ставящее в соответствие каждой странице ей рейтинг, который тем больше, чем больше документ d подходит к запросу q . Для оценки качества ранжирования нужен эталон $r_t(d)$, с которым будут сравниваться результаты.

MAP — метрика средней точности нахождения релевантных документов. Данная метрика применяется в том случае, если $r_t(d)$ принимает бинарные значения, т. е. каждый документ полностью либо релевантен либо нет.

Precision at N или точность на N элементах позволяет оценить долю релевантных документов среди первых N элементов ранжированного списка и рассчитывается по формуле:

$$p@N = \frac{1}{N} \sum_{k=1}^N r_t(P'(k)),$$

где P' — обратная перестановка, то есть $P'(k)$ — документ на k -ом месте после ранжирования.

Average precision at N позволяет учесть место, на котором оказался документ в ранжированном списке. Гораздо важнее увидеть релевантный документ на 1-ой позиции, чем в конце списка. Формула качества принимает следующий вид:

$$ap@N = \frac{1}{N} \sum_{k=1}^N [r_t(P'(k)) \cdot p@k],$$

Данная величина уже зависит от порядка. Она достигает максимума, если все релевантные документы находятся вверху ранжированного списка.

Mean average precision at N , в отличии от предыдущих метрик вычис-

ляется сразу для все запросов множества Q и является их средним. Пусть $|Q| = K$, тогда метрика записывается как:

$$map@N = \frac{1}{K} \sum_{j=1}^K ap@N_j,$$

В отличии от предыдущей группы метрик рассмотренные ниже NDCG можно использовать и при небинарных значениях r_t .

Cumulative gain at N . В простейшем случае суммируем все значения релевантностей документов среди N первых.

$$CG@N = \sum_{k=1}^N r_t(P'(k)).$$

Discounted cumulative gain at N . Модификация позволяет учесть порядок элементов в топе.

$$DCG@N = \sum_{k=1}^N \frac{2^{r_t(P'(k))} - 1}{\log_2(k + 1)}.$$

В данной метрике чем более релевантен документ, тем больше числитель. Знаменатель зависит от позиции документа, он штрафует за позицию документа в списке. Если документ очень релевантен, но занимает низкую позицию, то штраф будет большим, иначе маленьким. метрика достигает максимума, если все релевантные документы находятся в топе поисковой выдачи.

Normalized discounted cumulative gain at N . Призвана нормализовать результаты предыдущей метрики.

$$DCG@N = \frac{DCG@N}{maxDCG@N},$$

где $maxDCG@N$ — значение метрик при идеальном ранжировании.

3.2 Сравнение алгоритмов

Сравнение алгоритмов производилось по наборам данных таких коллекций как: AOL, LETOR 2.0, LETOR 3.0, LETOR 4.0, MSLR, WCL2R, Yahoo! Learning to Rank Challenge, Yandex Internet Mathematics 2009 contest. В самих датасетах содержатся не документы, а векторы их признаков. Таким образом, любая разница в производительности ранжирования обусловлена алгоритмом ранжирования, а не используемыми функциями.

Для оценки общей эффективности обучения методам ранжирования используется показатель «выигрышное число» [9]. Оно определяется как количество алгоритмов, которое алгоритм может превзойти на наборе датасетов, или более формально

$$\text{WN}_i(M) = \sum_{j=1}^n \sum_{k=1}^m I_{\{M_i(j) > M_k(j)\}},$$

где j — номер набора данных, n — кол-во наборов данных, i, k — индексы алгоритмов, $M_i(j)$ — производительность i -го алгоритма на j -ом наборе данных и $I_{\{M_i(j) > M_k(j)\}}$ — индикаторная функция, такая что

$$I_{\{M_i(j) > M_k(j)\}} = \begin{cases} 1 & \text{если оба определены и } M_i(j) > M_k(j) \\ 0 & \text{иначе} \end{cases}.$$

Будем использовать нормализованное «выигрышное число», для удобства интерпретации результатов, определённое как:

$$\text{NWN}_i(M) = \frac{\text{WN}_i(M)}{\text{IWN}_i(M)},$$

где $\text{IWN}_i(M)$ — идеальное «выигрышное число», то есть теоретически наибольшее число, которое было бы у алгоритма в случае, если бы он был наиболее точным. Определяется как:

$$\text{IWN}_i(M) = \sum_{j=1}^n \sum_{k=1}^m D_{\{M_i(j) > M_k(j)\}},$$

где индикаторная функция имеет значение

$$D_{\{M_i(j) > M_k(j)\}} = \begin{cases} 1 & \text{если оба определены} \\ 0 & \text{иначе} \end{cases} .$$

Согласно [9] результаты замеров приведены в таблице 3.1.

Таблица 3.1 – Результаты замеров производительности методов обучения ранжированию

	NDCG@3		NDCG@5		NDCG@10		MAP	
Метод	NWN	к.д.	NWN	к.д.	NWN	к.д.	NWN	к.д.
Linear Regression	0.0754	9	0.1099	9	0.0829	8	0.0650	8
Ranking SVM	0.3014	12	0.3613	11	0.4496	17	0.3400	13
LambdaRank	0.2000	1	0.2000	1	0.5714	2	-	-
ListNet	0.4480	12	0.4911	12	0.5982	12	0.4504	12

3.3 Вывод

Лучше всех себя показал алгоритм ListNet (списочный подход). На основе данной выборки методов, сложно сказать что списочный подход даёт лучшие показатели метрик чем остальные, так как она довольно мала, однако в большинстве случаев так и есть.

ЗАКЛЮЧЕНИЕ

Цель, которая была поставлена в начале научно-исследовательской работы, была достигнута: рассмотрены алгоритмы машинного обучения, применяемые в поисковых системах.

Решены все поставленные задачи:

- изучены основные понятия алгоритмов обучения ранжированию;
- приведены существующие алгоритмы и классифицированы;
- произведён сравнительный анализ рассмотренных алгоритмов.

В ходе исследования были определены особенности, преимущества и недостатки рассмотренных методов обучения ранжированию.

Лучшим с точки зрения показателей метрик оказался алгоритм ListNet (списочный подход). В основном списочные алгоритмы превосходят остальные подходы по показателям метрик, но они сложны в разработке и подборе обучающих наборов данных.

Для алгоритмов с попарным подходом могут быть применены существующие методологии классификации непосредственно, что ускоряет и упрощает процесс их разработки. Однако у данного подхода есть ряд недостатков:

- целью обучения таких алгоритмов является минимизация ошибок в классификации пар документов, а не минимизация ошибок в ранжировании документов;
- процесс обучения требует больших вычислительных затрат, поскольку количество пар документов очень велико;
- количество сгенерированных пар документов в значительной степени варьируется от запроса к запросу, что приводит к обучению модели, ориентированной на запросы с большим количеством пар.

Алгоритмы же с поточенным подходом являются самыми простыми и наименее производительными.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Бурков А. Машинное обучение без лишних слов / А. Бурков. — СПб.: Питер, 2020. — 192 с.
2. Городилов А. Методы машинного обучения для задачи ранжирования / А. Городилов // Труды Третьей Российской конференции молодых ученых по информационному поиску. — 2009. — С. 12–20.
3. Борисовская А. А. Применение методов машинного обучения в задачах ранжирования в поисковых информационных системах. / А. А. Борисовская // Информационные технологии в управлении. — 2021. — С. 1–13.
4. Cossack D. Subset ranking using regression / Cossack D., Zhang T.// In Proceedings of the 19th Annual Conference on Learning Theory (COLT). — 2006. — P. 605–619.
5. Herbrich R. Support vector learning for ordinal regression / Herbrich R., Graepel T., Obermayer K. // In International Conference on Artificial Neural Networks. — 1999. — P. 97–102.
6. Burges C. J. Learning to rank with nonsmooth cost functions / Burges C. J., Ragno R., Le Q. V. // Advances in Neural Information Processing Systems 19. — 2007. — P. 193–200.
7. Z. Cao Learning to rank: From pairwise approach to listwise approach / Z. Cao, T. Qin, T.-Y. Liu et al. // Proceedings of the 24th International Conference on Machine Learning. — 2007. — P. 129–136.
8. Беляков А.В Метрики качества в задачах ранжирования информации / Беляков А.В // Информационные технологии, межвузовский сборник научных трудов. — Рязань: Рязанский государственный радиотехнический университет имени В.Ф. Уткина. — 2019. — С. 36–39.
9. Niek Tax A Cross-Benchmark Comparison of 87 Learning to Rank Methods / Niek Tax, Sander Bockting, Djoerd Hiemstra // Information Processing and Management. — 2015. P. 757–772.

ПРИЛОЖЕНИЕ А Презентация научно-исследовательской работы

Презентация научно-исследовательской работы содержит 10 слайдов, на которых представлено краткое описание научно-исследовательской работы.